1/ Vérifier que Hadoop et Java sont correctement installés.

hadoop version javac -version



2/ Créer un répertoire " Lab" sur le bureau avec deux sous-répertoires "Input" et "tutorial_classes".

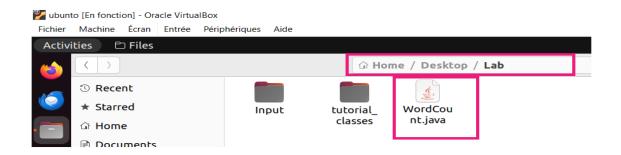
```
cd Desktop
mkdir Lab
mkdir Lab/Input
mkdir Lab/tutorial_classes
```



```
rahma@rahma-VirtualBox:~$ cd Desktop
rahma@rahma-VirtualBox:~/Desktop$ mkdir Lab
rahma@rahma-VirtualBox:~/Desktop$ mkdir Lab/Input
rahma@rahma-VirtualBox:~/Desktop$ mkdir Lab/tutorial_classes
```

3/créer le fichier "WordCount.java" dans le répertoire "Lab".

♣ Taper: touch WordCount.java



♣ File: WordCount.java

```
import java.io.IOException;
import java.util.StringTokenizer;
import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.Mapper;
import org.apache.hadoop.mapreduce.Reducer;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
// WordCount
public class WordCount {
// Classe TokenizerMapper
 public static class TokenizerMapper
    extends Mapper<Object, Text, Text, IntWritable>{
```

// Méthode map

int sum = 0;

private Text word = new Text();

```
public void map(Object key, Text value, Context context
         ) throws IOException, InterruptedException {
 StringTokenizer itr = new StringTokenizer(value.toString());
 while (itr.hasMoreTokens()) {
  word.set(itr.nextToken());
  context.write(word, one);
 }}}
 // Classe IntSumReducer
 public static class IntSumReducer
 extends Reducer<Text,IntWritable,Text,IntWritable> {
private IntWritable result = new IntWritable();
public void reduce(Text key, Iterable<IntWritable> values,
           Context context
           ) throws IOException, InterruptedException {
```

```
sur Hadoop en utilisant MapReduce.
  for (IntWritable val : values) {
   sum += val.get(); }
      result.set(sum);
  context.write(key, result);
 }}
// Méthode principale
public static void main(String[] args) throws Exception {
 Configuration conf = new Configuration();
 Job job = Job.getInstance(conf, "word count");
 job.setJarByClass(WordCount.class);
 job.setMapperClass(TokenizerMapper.class);
 job.setCombinerClass(IntSumReducer.class);
 // Optionnel, pour réduire le trafic de données
 job.setReducerClass(IntSumReducer.class);
 job.setOutputKeyClass(Text.class);
 job.setOutputValueClass(IntWritable.class);
 // Chemin d'entrée
```

FileInputFormat.addInputPath(job, new Path(args[0]));

Une explication du programme WordCount.

1. Classe WordCount

• **Fonctionnalité** : Contient la méthode main, qui initialise la configuration, définit les classes Mapper et Reducer, et gère les chemins d'entrée et de sortie.

2. Classe TokenizerMapper

• Fonctionnalité :

Méthode map : Divise chaque ligne en mots à l'aide de StringTokenizer. Chaque fois qu'un mot est trouvé, une occurrence de 1 lui est attribuée, permettant ainsi de compter le nombre total d'occurrences de chaque mot

3. Classe IntSumReducer

• Fonctionnalité:

Méthode reduce : Prend un mot (clé) et un ensemble de valeurs (occurrences). Calcule la somme des occurrences pour chaque mot et écrit le mot avec son total dans le contexte, produisant ainsi le résultat final du comptage.

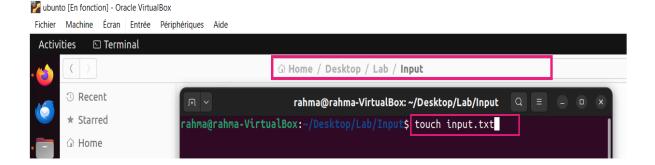
4. Méthode main

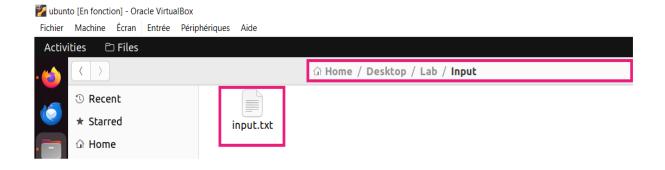
• Fonctionnalité:

Configure le job MapReduce, spécifie les classes Mapper et Reducer, définit les types de clés et de valeurs, et gère les chemins d'entrée et de sortie. Lance le job et gère la sortie du programme en fonction de Exécution complète du traitement. Bouaziz Rahma Nombre d'occurrences de chaque mot sur Hadoop en utilisant MapReduce.

BigData

4/Ajouter le fichier "input.txt" dans le répertoire "Lab/Input".

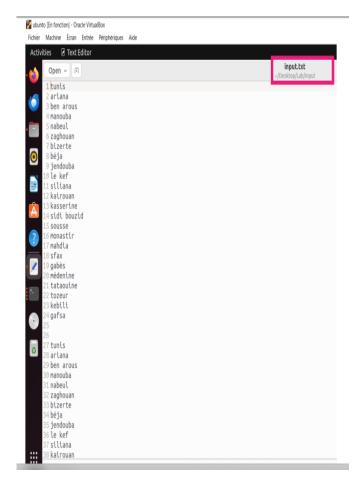




File: input.txt

tunis tunis ariana ariana ben arous ben arous manouba manouba nabeul nabeul zaghouan zaghouan bizerte bizerte béja béja jendouba jendouba le kef le kef siliana siliana kairouan kairouan kasserine kasserine sidi bouzid sidi bouzid sousse sousse monastir monastir mahdia mahdia sfax sfax gabès gabès médenine médenine tataouine tataouine tozeur tozeur kebili kebili gafsa

gafsa



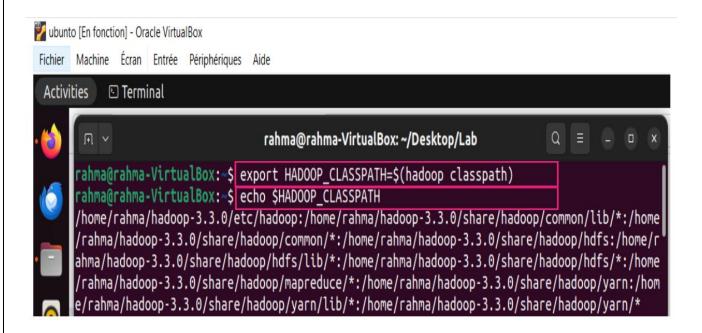
Bouaziz Rahma Nombre d'occurrences de chaque mot sur Hadoop en utilisant MapReduce.

BigData

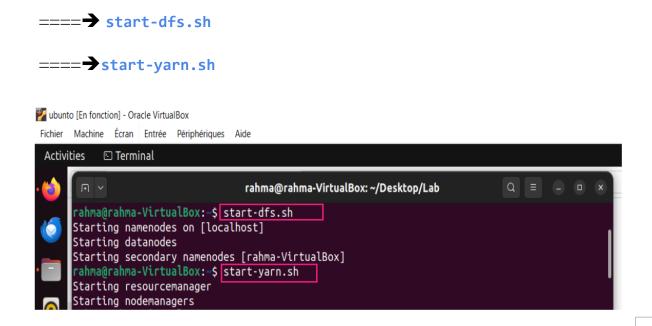
5/ Exporter le classpath Hadoop dans la variable d'environnement.

```
export HADOOP_CLASSPATH=$(hadoop classpath)
  echo $HADOOP_CLASSPATH
```

===→Cette commande configure la variable d'environnement HADOOP_CLASSPATH pour inclure les chemins nécessaires aux bibliothèques Hadoop, afin de faciliter l'exécution des programmes Hadoop.



Démarrer les services DFS et YARN dans Hadoop



Bouaziz Rahma Nombre d'

Nombre d'occurrences de chaque mot sur Hadoop en utilisant MapReduce. BigData

6/ Créer les répertoires nécessaires sur le système de fichiers HDFS.

hadoop fs -mkdir /WordCountTutorial

===== → Cette commande crée un répertoire nommé /WordCountTutorial dans le système de fichiers Hadoop (HDFS).

hadoop fs -mkdir /WordCountTutorial/Input

===== → Cette commande crée un dossier *Input* dans le dossier *WordCountTutorial* dans le système de fichiers Hadoop (HDFS).

hadoop fs -put Lab/Input/input.txt /WordCountTutorial/Input

==== Cette commande copie le fichier input.txt depuis le répertoire local Lab/Input/ vers le répertoire /WordCountTutorial/Input du système de fichiers HDFS.

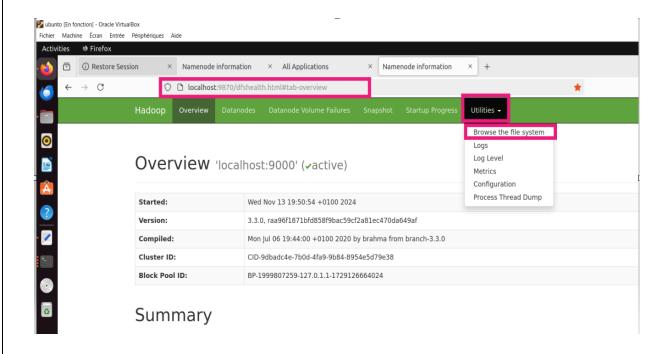
```
rahma@rahma-VirtualBox:~$ hadoop fs -mkdir /WordCountTutorial
rahma@rahma-VirtualBox:~$ hadoop fs -mkdir /WordCountTutorial/Input
```

rahma@rahma-VirtualBox:~/Desktop\$ hadoop fs -put Lab/Input/input.txt /WordCountTutorial/Input

7/Vérifier l'existence des répertoires et fichiers sur l'interface web de Hadoop.

Hadoop NameNode ===> http://localhost:9870

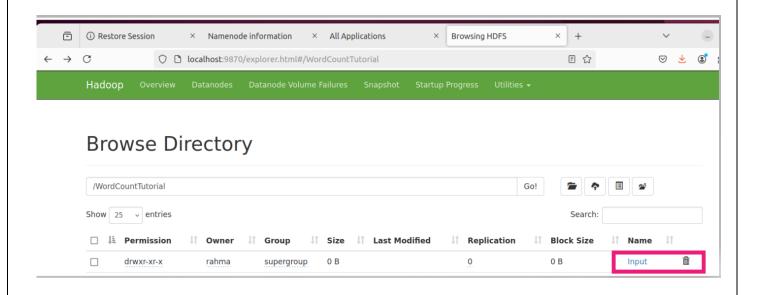
=====→Allez à localhost:9870 depuis le navigateur, ouvrez "Utilitaires → Parcourir le système de fichiers" et vous devriez voir les répertoires et fichiers que nous avons placés dans le système de fichiers.

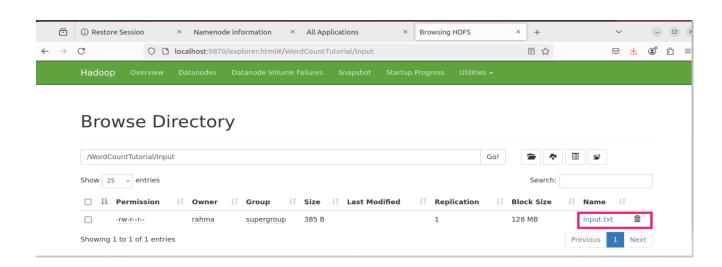


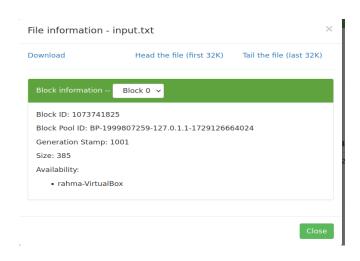
Bouaziz Rahma

Nombre d'occurrences de chaque mot sur Hadoop en utilisant MapReduce.

BigData







8/ Compiler le code Java WordCount.java et créer un fichier jar.

```
cd Desktop
cd Lab
javac -classpath $HADOOP_CLASSPATH -d tutorial_classes WordCount.java
=====→ Cette commande compile les fichiers Java avec le classpath
Hadoop et place les classes compilées dans le dossier tutorial_classes.
jar -cvf WordCount.jar -C tutorial_classes .
=====→ Mettre les fichiers de sortie dans un seul fichier jar.
```

```
rahma@rahma-VirtualBox:~/Desktop$ cd Lab
rahma@rahma-VirtualBox:~/Desktop/Lab$ javac -classpath $HADOOP_CLASSPATH -d tutorial_classes WordCount.java
rahma@rahma-VirtualBox:~/Desktop/Lab$ jar -cvf WordCount.jar -C tutorial_classes .

added manifest
adding: WordCount$TokenizerMapper.class(in = 1736) (out= 754)(deflated 56%)
adding: WordCount$IntSumReducer.class(in = 1739) (out= 739)(deflated 57%)
adding: WordCount.class(in = 1491) (out= 814)(deflated 45%)
```

9/ Exécuter le programme WordCount en utilisant le fichier jar sur Hadoop.

hadoop jar WordCount.jar WordCount /WordCountTutorial/Input /WordCountTutorial/Output

======→ Cette commande exécute le programme WordCount en utilisant WordCount.jar, en prenant les données d'entrée depuis /WordCountTutorial/Input et en écrivant les résultats dans /WordCountTutorial/Output dans HDFS.

```
rahma@rahma-VirtualBox:-/Desktop/Lah$ hadoop jar WordCount.jar WordCount/WordCountTutorial/Input /WordCountTutorial/Output
2024-11-13 20:46:58,304 INFO client.DefaultWoHARMFailoverProxyProvider: Connecting to ResourceManager at /127.0.0.1:8032
2024-11-13 20:47:00,073 WARN mapreduce. JobResourceUploader: Hadoop command-line option parsing not performed. Implement the Tool interface and execute your application
with ToolRunner to remedy this.
2024-11-13 20:47:00,186 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding for path: /tmp/hadoop-yarn/staging/rahma/.staging/job_1731523957744_0001
2024-11-13 20:47:01,324 INFO input.FileInputFormat: Total input files to process: 1
2024-11-13 20:47:01,635 INFO mapreduce.JobSubmitter: number of splits:1
2024-11-13 20:47:02,429 INFO mapreduce. JobSubmitter: Submitting tokens for job: job 1731523957744 0001
2024-11-13 20:47:02,429 INFO mapreduce.JobSubmitter: Executing with tokens: []
2024-11-13 20:47:03,422 INFO conf.Configuration: resource-types.xml not found
2024-11-13 20:47:03,423 INFO resource.ResourceUtils: Unable to find 'resource-types.xml'.
2024-11-13 20:47:04,881 INFO impl.YarnClientImpl: Submitted application application_1731523957744_0001
2024-11-13 20:47:05,226 INFO mapreduce.Job: The url to track the job: http://rahma-VirtualBox:8088/proxy/application 1731523957744 0001/
2024-11-13 20:47:05,230 INFO mapreduce. Job: Running job: job 1731523957744 0001
2024-11-13 20:47:32,702 INFO mapreduce. Job: Job job_1731523957744_0001 running in uber mode : false
2024-11-13 20:47:32,706 INFO mapreduce.Job: map 0% reduce 0%
2024-11-13 20:47:47,340 INFO mapreduce.Job: map 100% reduce 0%
2024-11-13 20:47:59,660 INFO mapreduce.Job: map 100% reduce 100%
2024-11-13 20:48:00,717 INFO mapreduce.Job: Job job_1731523957744_0001 completed successfully
2024-11-13 20:48:01,132 INFO mapreduce.Job: Counters: 54
```

```
bytes written=527959
                          Number
                         Number of
Number of
                                             read operations=0
                                            large read operations=0
write operations=0
bytes read=505
bytes written=245
                          Number of
                          Number of
                          Number
                                      of
                                             read operations=8
                                             large read operations=0 write operations=2
                          Number
                                      of
              HDES:
                          Number of
              HDFS:
                         Number of
                                             bytes read erasure-coded=0
Job Counters
               Launched map tasks=1
              Launched reduce tasks=1
Data-local map tasks=1
                                  spent by all maps in occupied slots (ms)=11350 spent by all reduces in occupied slots (ms)=9466 spent by all map tasks (ms)=11350 spent by all reduce tasks (ms)=9466
                         time
                         time spent by all reduce tasks (MS)=91666
vcore-milliseconds taken by all map tasks=11350
vcore-milliseconds taken by all reduce tasks=94
megabyte-milliseconds taken by all map tasks=11
                                                                               all reduce tasks=9466
                                                                                                    tasks=11622400
```

```
Map-Reduce Framework
        Map input records=51
        Map output records=54
        Map output bytes=598
        Map output materialized bytes=359
        Input split bytes=120
        Combine input records=54
        Combine output records=27
        Reduce input groups=27
        Reduce shuffle bytes=359
        Reduce input records=27
        Reduce output records=27
        Spilled Records=54
        Shuffled Maps =1
        Failed Shuffles=0
        Merged Map outputs=1
        GC time elapsed (ms)=384
        CPU time spent (ms)=2000
        Physical memory (bytes) snapshot=329822208
        Virtual memory (bytes) snapshot=4972486656
        Total committed heap usage (bytes)=170004480
        Peak Map Physical memory (bytes)=216195072
        Peak Map Virtual memory (bytes)=2482933760
        Peak Reduce Physical memory (bytes)=113627136
        Peak Reduce Virtual memory (bytes)=2489552896
```

```
Shuffle Errors

BAD_ID=0

CONNECTION=0

IO_ERROR=0

WRONG_LENGTH=0

WRONG_MAP=0

WRONG_REDUCE=0

File Input Format Counters

Bytes Read=385

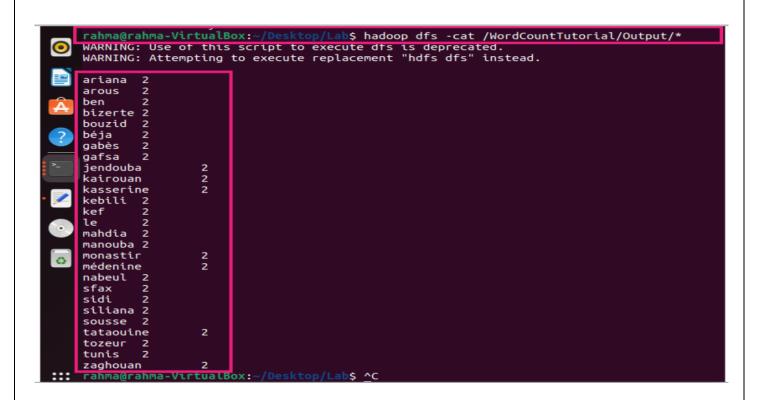
File Output Format Counters

Bytes Written=245
```

10/ Afficher les résultats de l'exécution à partir du répertoire de sortie HDFS.

```
cd Desktop
cd Lab
hadoop dfs -cat /WordCountTutorial/Output/*
```

====== Cette commande affiche le contenu de tous les fichiers dans le répertoire /WordCountTutorial/Output dans le système de fichiers Hadoop (HDFS).



Remarque

Pour exécuter cette commande "hadoop dfs -cat /WordCountTutorial/Output/*", il faut d'abord démarrer les services DFS et YARN dans Hadoop :

start-dfs.sh start-yarn.sh